淘宝推荐系统
技术调研报告

从全链路架构到生成式AI的演进之路

核心驱动：
算法创新 × 极致工程 × 业务理解

汇报人：姚凯方

2026年4月3日

小组成员：顾奕博 周楚然 张文宇

淘宝推荐系统：全链路架构解析

技术底座：AI•OS

搜索、推荐、广告三大场景一体化管理

- 端到端优化
- 场景间模型与数据共享
- 分钟级别模型更新能力

搜索引擎：HA3

高性能在线搜索引擎，支撑淘宝**数亿商品**的实时检索

- 万亿级数据秒级索引（分布式、压缩索引等技术）
- 深度集成深度学习模型（匹配和排序一起完成）
- 支持复杂的多维过滤（多个筛选条件）

资源管理：Hippo

底层分布式资源调度引擎，为海量计算提供弹性支撑。

- 毫秒级资源调度响应
- 异构计算资源统一管理
- 极致的成本效能平衡

推荐流程：四大核心阶段的全景视图

1. 召回 (Recall)

50ms 内从数亿商品中筛选出万级候选集，追求高召回率。

2. 粗排 (Pre-ranking)

使用轻量级模型对万级商品进行初步打分筛选。

3. 精排 (Ranking)

利用复杂深度学习模型进行精细化打分，追求极致精度。

4. 重排 (Re-ranking)

平衡用户体验、多样性与商业价值，确定最终列表。

召回阶段
规模：数亿 → 万级

粗排阶段
规模：万级 → 千级

精排阶段
规模：千级 → 百级

重排阶段
规模：百级 → 最终展示

召回阶段：大规模高效筛选技术

核心技术：双塔向量检索

独立编码： 将用户画像与商品特征独立编码为高维向量，实现解耦。

高效度量： 采用余弦相似度，通过 L2 归一化简化为极速的点积计算。

工业级应用： 支撑数亿级商品库在 50ms 内完成万级候选集筛选。

自研向量索引引擎

性能突破： 针对电商场景深度优化的索引结构，远超开源方案。

10x	-75%
检索速度提升	资源消耗降低

对比 FAISS： 在保持同等精度的前提下，实现了吞吐量与成本的极致平衡。

召回策略创新：多维感知与兴趣挖掘突破

多模态召回

“拍立淘”技术对齐

通过深度学习将图像特征与文本语义映射到统一向量空间。

- 跨模态语义检索
- 解决“描述难”的搜索痛点
- 提升非结构化数据利用率

冷启动策略

多序列行为融合

针对新用户或新商品，利用跨域行为和属性特征进行快速建模。

- 融合点击、收藏、加购序列
- 基于属性的相似度迁移
- 缩短兴趣捕捉周期

图神经网络 (GNN)

复杂兴趣关联挖掘

在闲鱼等轻应用中，利用图结构捕捉用户与商品间的深层联系。

- 高阶邻居特征聚合
- 挖掘潜在的社交/兴趣圈层
- 提升长尾商品的曝光精度

* 核心目标：突破单一维度限制，实现对用户兴趣的全方位、多层次感知。

排序模型演进（上）——从逻辑回归到深度兴趣网络

推荐系统排序模型经历了从线性到非线性、从静态到动态的三次关键演进

LR + GBDT

01

2010s初期

- **机制：**逻辑回归(LR)处理线性特征，GBDT负责特征交叉工程
- **瓶颈：**特征交叉严重依赖人工设计，无法有效捕捉高阶非线性关系

Wide & Deep

02

2016年

- **机制：**Wide侧记忆历史共现模式(Memorization)，Deep侧泛化至未见特征组合(Generalization)
- **突破：**首次将记忆与泛化能力在同一深度学习模型中完美结合

DIN & DIEN

03

2018-2019年

DIN (深度兴趣网络)

创新：捕捉"即时兴趣"

机制：注意力机制，对目标商品相关的历史行为赋予更高权重

DIEN (深度兴趣演化网络)

创新：建模兴趣动态演变

机制：GRU + 注意力门控，追踪兴趣随时间的漂移轨迹

关键洞察：DIN的注意力机制使模型不再对所有历史行为一视同仁，而是聚焦与当前候选商品最相关的行为信号。

排序模型演进（下）——ESMM解决样本偏差与RecGPT的范式革命

ESMM：全空间多任务模型 (2018)

面临挑战：样本选择偏差

传统CVR（转化率）预测模型只能在点击样本上训练，但预测时需覆盖全部曝光商品，导致严重的样本选择偏差。

解决方案：联合建模

联合建模 CTR（点击率）与 CVR（转化率），在全曝光空间上进行优化，消除偏差。

$$pCTCVR = pCTR \times pCVR$$

业务效果

通过乘积关系将CVR训练信号扩展至全空间，在相同曝光下，GMV（商品交易总额）获得显著提升。

RecGPT：生成式推荐的范式转变 (2024+)

任务范式	预测点击/购买概率	**生成个性化推荐理由与序列**
模型规模	亿级参数	**百亿级参数**
特征理解	结构化特征	**多模态认知（图文音视频）**
训练方式	监督学习	**监督学习 + 强化学习(RLHF)**

战略意义： *RecGPT标志着推荐系统从"预测用户行为"向"理解用户意图并主动生成内容"的根本性转变，开启了推荐系统的新纪元。*

重排与支撑：通用表征与自监督学习的应用

生成式重排技术

利用大语言模型（LLM）对推荐列表进行全局优化。

- **列表润色**：优化推荐结果的连贯性与多样性。
- **上下文感知**：捕捉列表内商品间的相互影响。
- **用户体验**：提升整体浏览的沉浸感。

通用表征模型：MOON

面向电商场景的多模态通用预训练模型。

- **多模态融合**：统一建模图像、文本与行为数据。
- **跨场景迁移**：支持搜索、广告、推荐大盘。
- **效果显著**：使全站点击率（CTR）提升 20%。

自监督学习 (SSL)

利用海量无标签数据增强模型的泛化能力。

- **对比学习**：通过数据增强构建正负样本对。
- **缓解稀疏性**：解决长尾商品标注不足的问题。
- **鲁棒性增强**：提升模型在噪声数据下的稳定性。

行业横向对比——技术选型背后的商业逻辑

淘宝 (阿里巴巴)

技术标签

平台化 · 算法前瞻

核心算法

DIN / ESMM / RecGPT

隐私保护

差分隐私 + 联邦学习

推荐目标

用户体验 + 生态繁荣

冷启动策略

多序列行为融合

京东

技术标签

供应链深度融合

核心算法

供应链感知排序

隐私保护

量子密钥分发 (QKD)

推荐目标

履约确定性 + 合规安全

冷启动策略

供应链信号辅助

拼多多

技术标签

极致性价比驱动

核心算法

高效分层联邦学习

隐私保护

分层联邦学习

推荐目标

爆款营销 + 极速转化

冷启动策略

社交裂变信号

核心洞察：商业模式决定技术选型

淘宝的开放平台生态要求算法具备极强的泛化能力；**京东**的自营模式使其能将库存、物流数据深度融入排序信号；**拼多多**的社交拼团模式天然产生群体行为信号，联邦学习在保护隐私的同时实现高效协同。

技术复现路径与战略启示

技术复现路径

1 基础建设阶段

从双塔向量召回开始，搭建高性能检索系统，解决“从无到有”的规模化筛选选问题。

2 核心模型迭代

依次引入 WDL、DIN、ESMM 等成熟排序模型，通过捕捉用户兴趣与解决样样本偏差提升精度。

3 前沿探索阶段

探索多模态特征融合与 LLM 生成式重排技术，实现从“预测”到“生成”的范式转移。

核心战略启示

卓越推荐系统 =

算法创新 ×

极致工程 ×

业务理解

技术不应孤立存在，只有将前沿算法与稳健的工程底座、深刻的业务洞察相结合，才能在电商激烈的竞争中创造真正的商业价值。