

经验软件工程二讲稿

第一页

大家好，我是XXX，我们小组的汇报主题是“面向AI生成代码的人工审核与智能支持”。随着生成式AI在软件开发领域的普及，代码审核面临着新的挑战 and 机遇。本次汇报将分享我们关于如何通过智能支持提升人工审核效率和质量的实证研究。

第二页

首先，我们来看研究背景。生成式AI正在重塑代码审核流程。我们面临三大核心挑战：审核量激增、新的未知缺陷类型，以及责任界定的复杂化。数据显示，Copilot的使用使得代码生成量大幅增长，同时我们的预调研也发现人工审核的延迟显著增加。这张流程图对比了传统与AI时代的审核流程，而Copilot的界面则直观展示了AI如何融入开发环境。

第三页

基于这些挑战，我们的研究目标是系统评估智能支持对AI生成代码审核的效果。我们发现现有研究在场景适配、协同机制和评估维度上存在缺口。因此，我们的研究聚焦于AI生成代码场景，设计了人机协作流程，并从质量、效率和认知负荷三个维度进行综合评估。这正符合“人类主导、AI增强”的软件工程3.0新范式。

第四页

为了实现研究目标，我们提出了四个核心研究问题及相应假设。我们想知道智能支持是否能提升审核质量、不同方法是否存在差异、是否能降低审核成本，以及代码特征是否会调节支持效果。所有假设检验都将遵循严格的统计标准。

第五页

在实验设计中，我们对比了三种主流的代码评审方法。方法A是基于SonarQube的规则驱动静态分析，作为基线。方法B是结合了代码度量和XGBoost的混合机器学习模型。方法C是我们重点关注的前沿方法，基于CodeLlama进行微调的智能体。这种设计形成了清晰的技术梯度，有助于我们评估不同智能水平的支持效果。

第六页

我们的实验数据集包含212条代码片段，结合了真实的开源PR和我们注入缺陷的AI生成代码。所有变量都经过精心设计，包括作为自变量的评审方法和代码特征，以及作为因变量的质量、效率和认知负荷指标。我们采用了严谨的混合设计，并控制了潜在的干扰变量，以确保实验结果的可靠性。

第七页

在实验实施过程中，我们采取了一系列关键控制措施来保证实验的科学性。例如，我们采用盲法设计和强制流程来避免偏见，并通过严格的疲劳控制保证参与者状态。同时，我们也解决了诸如LLM延迟和标注分歧等实际问题，确保了实验的顺利进行。

第八页

现在我们来看核心结果。首先是描述性统计。从左侧的图表中可以清晰地看到，随着智能支持水平的提升，审核的召回率（青色柱）和精确率（白色柱）都在稳步提高。

右侧展示了具体的效能提升细节，特别是Method-C（LLM智能体），在所有三个核心指标上都表现出显著优势。它的召回率达到了0.83，精确率0.89，不仅在质量上最优，在效率上也是最快的，审核时长仅需31.5秒，相比Control组缩短了近20秒。

最后，底部的标注显示，统计检验证实Method-C的效果在 $p < 0.01$ 的水平上显著优于对照组，这证明了该方案的可靠性。

第九页

接下来是假设检验的汇总。所有四个研究问题的假设都得到了统计上的显著支持。特别是对于审核时长的降低，效应量 d 达到了1.82，这是一个极大的效应，说明智能支持在提升效率方面效果非常显著。同时，方法类型对审核质量的解释度也达到了29%，证明了其重要性。

第十页

为了更直观地展示结果，我们进行了关键可视化。效率-质量散点图显示，Method-C实现了效率和质量的双赢。复杂度调节效应图则揭示了LLM智能体在处理复杂任务时的独特优势。而人机协作热图的数据进一步印证了我们的观点：智能是增强人类，而不是替代人类。

第十一页

现在，我们对四个研究问题进行逐条回答。简单来说，智能支持确实能提升审查质量、不同方法存在显著差异、能大幅降低审核成本，并且代码特征会调节支持效果。这些结论为我们如何在实践中应用智能审核工具提供了明确的指导。

第十二页

总结一下，我们的研究得出了三个核心结论：智能支持实现了质量与效率的双赢，存在明显的智能梯度效应，并且证明了人类主导的人机协作模式是可行的。基于这些结论，我们提出了分层介入、交互优化和团队适配三条实践建议。正如我们的金句所说，智能的真正价值在于增强人类的判断力。

第十三页

当然，我们的研究也存在一些局限性，比如样本和任务的局限性。未来，我们计划向多模态审核、个性化智能体和责任机制等方向深入探索。我们承诺将开源本次研究的相关资源，以促进该领域的发展。最后，感谢所有为本研究做出贡献的老师 and 同学。我的汇报到此结束，欢迎提问。