软件工程与计算III

迭代一问题汇总、迭代二任务说明

软件学院-2026

1. 迭代一截止时间?

3.30 晚 23:59；尚未在nju table中填写gitlab群组地址的请尽快填写

2. 复现什么？如何复现?

- 不需要复现整个项目，只复现相关**指标的计算过程**
- 文档阅读标注任务：只需要阅读Ragas中与Agent评估指标相关部分即可

3. CI/CD要求

- 过程加分项，不做强制要求，可以使用 Jenkins 与 Gitlab runner 以外的产品。
- 迭代二开始，迭代三才开始的不计入加分
- 需保证迭代二和迭代三最后一次提交构建是成功的

4. 项目制申报

- 迭代二的主题确定后就可以开始填写了；
- 项目依托课程填写本课程
- **项目所属批次：2026年春季学期**

不要在代码中硬编码API Key，可以使用环境变量、配置加载、用户交互输入等各种方式！

■ 迭代二任务介绍

迭代二产物： Agent应用 + Agent评估平台 + 文档

迭代时间： 6 weeks

检查方式： 5-10min演示视频，**视频链接**放在仓库指定位置

演示视频包括agent应用、agent评估平台使用演示，以及对agent应用实现架构的介绍

■ 迭代二任务介绍 – 任务一

目标：搭建一个面向特定领域的，具备自主思考和行动能力的LLM Agent应用

主题：不限，生活类、科研助手类、代码开发类、软工任务类…

基本需求点：

1. Agent需展现出规划和思考能力，而不是简单预定义的workflow；
2. Agent具备与外部世界交互的能力，根据自选主题，至少设计实现2个主题相关的外部工具；
3. Agent需具备自我修正能力，能够捕获系统中的异常并处理；
4. Agent需可视化内部状态流转情况（cli，web等各种形式均可）

加分项：

- Agent有机结合不止一种推理框架，如ReAct，plan-and-execute，reflexion等

■ 迭代二任务介绍 – 任务一

目标：搭建一个面向特定领域的，具备自主思考和行动能力的LLM Agent应用

主题：不限，生活类、科研助手类、代码开发类、软工任务类…

基本需求点：

1. Agent需展现出规划和思考能力，而不是简单预定义的workflow；
2. Agent具备与外部世界交互的能力，根据自选主题，至少设计实现2个主题相关的外部工具；
3. Agent需具备自我修正能力，能够捕获系统中的异常并处理；
4. Agent需可视化内部状态流转情况（cli，web等各种形式均可）

加分项：

- Agent有机结合不止一种推理框架，如ReAct，plan-and-execute，reflexion等

■ 迭代二任务介绍 – 任务一

- **自治Agent (Autonomous Agent) 与 Agentic工作流 (Agentic Workflow)**

  自治Agent强调自治，Agentic工作流强调预定义

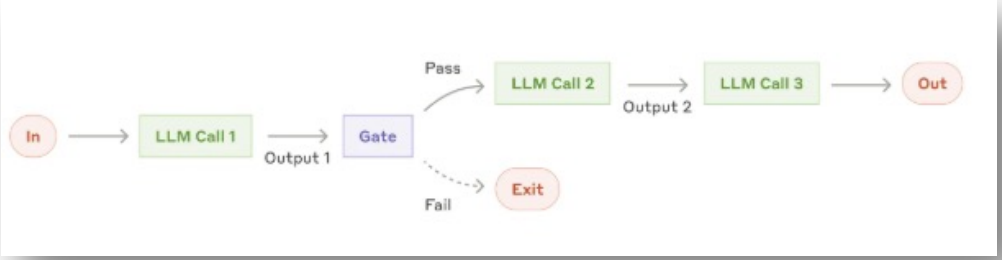

提示链工作流

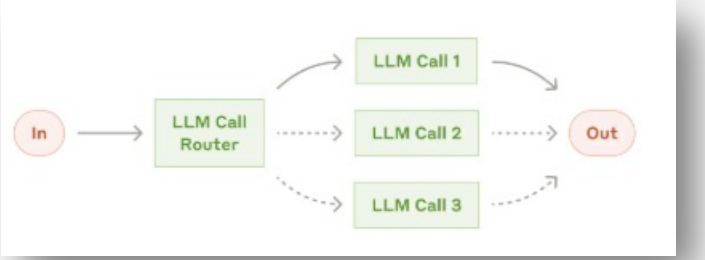

路由工作流

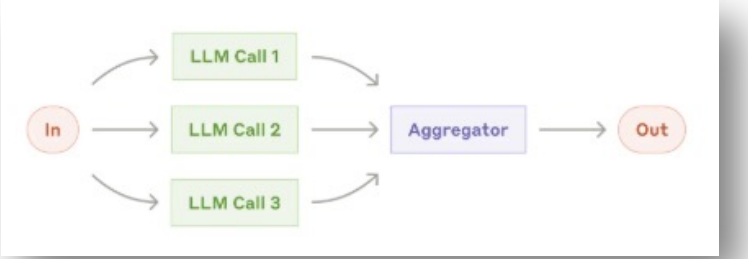

并行工作流

自治Agent

OPENCLAW

PI-AI

https://github.com/badlogic/pi-mono

■ 迭代二任务介绍 – 任务一

- **主题选择建议**

1. 领域内的任务类型丰富，任务路径具有高度的非确定性和开放性；
2. 任务面临动态变化的环境且需要不断试错

- **开发框架建议**

现有一些Agent开发框架，如LangChain、AutoGen；

选择框架需要考虑应用场景，不能一概而论；手搓可能是更好的选择

■ 迭代二任务介绍 – 任务二

目标：搭建一个Agent应用评估平台

基本约束：前后端分离Web项目，开发语言不要求，评估指标可以直接使用Ragas库

基本需求点：

评测任务管理能力：支持创建评测任务，支持配置评测任务（如Agent版本、数据集选择、评测方法选择等），支持评测任务增删改查和状态管理与展示

评测执行与方法能力：支持多种评测方法（三种划分不独立，相互间必然有重叠）

按评估模式划分：面向结果（只关注输入输出）/ 面向过程（关注 Agent 响应的中间过程）

按评估方式划分：显式指标（可以明确计算，如 Token 消耗、工具调用正确率、任务成功率、响应时间等）/ 模糊指标（评价标准相对主观，一般以 LLM-as-a-Judge 的模式实现，例如推理质量、输出内容准确性、幻觉程度、交互体验等，可以自行设计，也可以基于已有评估框架实现）

按评估维度划分：效果维度（任务响应是否有效、准确、完整）/ 安全（反馈信息是否安全，是否不包含有害内容）/ 性能（用户体验是否流畅，是否出现长时间停顿等待，是否有良好的互动交流体验）

扩展能力：支持自定义评估指标，支持组合评估策略

评测分析与展示能力：支持单次评估任务可视化结果展示，支持多个评估任务间对比分析与展示

■ 迭代二任务介绍 – 任务二

- **一些评估经验**

基于LLM-as-a-Judge的评估：

基于已有评估框架实现（优点：方便快捷好上手；缺点：灵活性差，定制化程度有限）

参考资料：LLM 智能体评测：工具使用、任务完成度、自主推理能力等多维度考察

参考资料：15分钟读懂大模型智能体评估：指标、框架与落地实践-腾讯云开发者社区-腾讯云

参考资料：智能体评测-涂鸦开发者平台-涂鸦开发者

参考已有评估框架的实现思路自行实现（优点：灵活性强，可高度定制化；缺点：工程量大）

参考资料：如何从零开始构建LLM评测框架